

XÂY DỰNG HỆ THỐNG PHÁT HIỆN GIAO DỊCH BẤT THƯỜNG VÀ SÀN LỌC RỬA TIỀN DỰA TRÊN MÔ HÌNH MÁY HỌC

Lê Nguyễn Hoàng Phú¹

¹ Đại học Sư phạm Kỹ thuật Vĩnh Long

22004079@st.vhute.edu.vn

TÓM TẮT— Gian lận tài chính và rửa tiền gây ra những mối đe dọa nghiêm trọng cho sự ổn định kinh tế toàn cầu. Tại Việt Nam, việc thực thi Luật 14/2022/QH15 và Thông tư 27/2025/TT-NHNN yêu cầu giám sát nghiêm ngặt các giao dịch tài chính. Các hệ thống Chống Rửa Tiền (AML) truyền thống chỉ dựa trên quy tắc tĩnh thường sinh ra tỷ lệ cảnh báo nhầm (false positive) rất cao, lãng phí nguồn lực của cán bộ điều tra. Đề xuất ML-ADAS, một hệ thống sàng lọc giao dịch AML ba lớp mới. Kiến trúc gồm: Động cơ Quy tắc Pháp định, lớp suy diễn Học Máy kết hợp mô hình LightGBM có giám sát với Bộ mã hóa tự động (Autoencoder) không giám sát, và bộ tổng hợp tính điểm rủi ro bằng Logic Mờ. Được đánh giá trên tập dữ liệu PaySim mất cân bằng cao, mô hình LightGBM tối ưu (tỉ lệ SMOTENC 0,2; ngưỡng 0,8504) đạt PR-AUC kiểm tra 0,9915, F1-Score 0,8873 và Tỷ lệ Cảnh báo Nhầm (FAR) cực thấp 0,0112%. Bộ mã hóa tự động bổ sung cung cấp tín hiệu bất thường mạnh mẽ với tỉ lệ phân tách 325,21 lần giữa sai số tái tạo trung bình của giao dịch bình thường và gian lận. Mô phỏng triển khai thực tế cho thấy ML-ADAS giảm thiểu đáng kể khối lượng xét duyệt thủ công trong khi vẫn phát hiện phần lớn hoạt động gian lận, đảm bảo tuân thủ nghiêm ngặt quy định AML của Việt Nam.

Từ khóa— Chống Rửa Tiền, LightGBM, Autoencoder, Logic Mờ, Mất Cân Bằng Lớp, SMOTENC, Quy định AML Việt Nam.

I. GIỚI THIỆU

Rửa tiền tạo điều kiện thuận lợi cho các tội phạm nghiêm trọng bằng cách che giấu nguồn gốc phi pháp của tài sản. Trong bối cảnh dịch vụ tài chính được số hóa nhanh chóng, khối lượng và tốc độ giao dịch đã tăng lên đáng kể, khiến việc giám sát thủ công và các hệ thống dựa trên quy tắc đơn giản dần trở nên lỗi thời. Tại Việt Nam, khung pháp lý điều chỉnh hoạt động phòng, chống rửa tiền (AML) đã được tăng cường đáng kể với sự ra đời của Luật 14/2022/QH15 [1] và Thông tư 27/2025/TT-NHNN [2]. Các quy định này yêu cầu thực hiện thẩm định khách hàng (CDD) chặt chẽ và giám sát giao dịch nghiêm ngặt.

Các hệ thống AML truyền thống chủ yếu dựa trên các quy tắc tĩnh, chẳng hạn như gán cờ tất cả các giao dịch vượt quá một ngưỡng tiền tệ định sẵn. Mặc dù các hệ thống này hỗ trợ tuân thủ pháp luật, chúng thường tạo ra số lượng cảnh báo nhầm (false positive) rất lớn, dẫn đến tình trạng “mệt mỏi cảnh báo” (alert fatigue) đối với các cán bộ tuân thủ. Để khắc phục vấn đề này, các kỹ thuật học máy (Machine Learning - ML) ngày càng được áp dụng nhằm phát hiện các mẫu phức tạp và phi tuyến tính đặc trưng cho gian lận tài chính.

Tuy nhiên, việc huấn luyện mô hình ML cho bài toán AML đặt ra một thách thức then chốt: mất cân bằng lớp cực độ. Các giao dịch gian lận thường chỉ chiếm một tỷ lệ rất nhỏ trong tổng số giao dịch, thường dưới 0,5%. Khi được huấn luyện một cách ngây thơ trên dữ liệu như vậy, mô hình có xu hướng thiên về lớp đa số, dẫn đến độ chính xác cao nhưng khả năng phát hiện gian lận thực sự lại kém.

Để giải quyết các thách thức trên và đồng thời phù hợp với khung pháp lý Việt Nam, nghiên cứu này giới thiệu ML-ADAS, một Hệ thống Phát hiện và Sàng lọc Gian lận Toàn diện. Các đóng góp chính của Nghiên cứu này được tóm tắt như sau:

- Kiến trúc ba lớp:** Hệ thống lai tích hợp các quy tắc pháp định tĩnh, các mô hình học máy tiên tiến và logic mờ, nhằm cân bằng giữa yêu cầu tuân thủ nghiêm ngặt và năng lực phát hiện gian lận thích ứng.
- Giảm thiểu mất cân bằng lớp:** Thực hiện khảo sát toàn diện kỹ thuật lấy mẫu vượt trội SMOTENC, qua đó chứng minh rằng tỷ lệ lấy mẫu vừa phải (0,2) kết hợp với LightGBM cho sự cân bằng tối ưu giữa Precision và Recall, đồng thời vượt trội so với XGBoost.
- Suy diễn hai tín hiệu và tổng hợp mờ:** Hệ thống kết hợp LightGBM có giám sát với Autoencoder (AE) không giám sát — AE cung cấp tín hiệu bất thường độc lập đạt tỷ lệ phân tách 325,21 lần — sau đó dùng logic mờ Mamdani để tổng hợp hai luồng tín hiệu này thành điểm rủi ro tính tế hơn và có khả năng giải thích tốt hơn.
- Phù hợp quy định:** Các quy tắc và cơ chế tính điểm rủi ro của hệ thống được ánh xạ rõ ràng với các điều khoản của Luật 14/2022/QH15 và Thông tư 27/2025/TT-NHNN.

II. TỔNG QUAN NGHIÊN CỨU

A. Học máy có giám sát trong AML

Các thuật toán học có giám sát, đặc biệt là các tổ hợp dựa trên cây quyết định, đã trở thành tiêu chuẩn cho dữ liệu gian lận dạng bảng. XGBoost và LightGBM được sử dụng rộng rãi do hiệu quả và tính bền vững với các mối quan hệ

phi tuyến [3], [4]. Phân tách dựa trên histogram của LightGBM thường cung cấp thời gian huấn luyện nhanh hơn và tiêu thụ bộ nhớ thấp hơn, điều này rất quan trọng cho các hệ thống AML thông lượng cao.

B. Xử lý mất cân bằng lớp

Tập dữ liệu tài chính vốn đã mất cân bằng. Các kỹ thuật như Kỹ thuật Lấy mẫu vượt trội Thiểu số Tổng hợp (SMOTE) tạo ra các ví dụ tổng hợp của lớp thiểu số. Đối với tập dữ liệu chứa cả đặc trưng số và phân loại, SMOTENC (SMOTE cho Danh nghĩa và Liên tục) được ưu tiên [5]. Các nghiên cứu gần đây cho thấy việc lấy mẫu vượt trội quá mức có thể làm méo phân phối gốc, do đó điều chỉnh tỉ lệ lấy mẫu là rất quan trọng.

C. Phát hiện bất thường không giám sát

Các mô hình không giám sát không phụ thuộc vào dữ liệu gian lận được gán nhãn, khiến chúng có giá trị trong việc phát hiện các loại hình gian lận mới. Bộ mã hóa tự động (AE), một loại mạng nơ-ron nhân tạo, được huấn luyện để tái tạo các giao dịch bình thường. Các giao dịch gian lận vốn dĩ tạo ra sai số tái tạo cao hơn [6]. Hệ thống của Nghiên cứu này sử dụng AE được huấn luyện độc quyền trên dữ liệu bình thường để tạo ra tín hiệu bất thường độc lập.

D. Khả năng giải thích

Khả năng giải thích là yêu cầu quan trọng để bảo đảm minh bạch và giải trình trong mô hình quản trị rủi ro tài chính. Với mô hình học có giám sát, nghiên cứu sử dụng SHAP để lượng hóa mức đóng góp của từng đặc trưng vào kết quả dự đoán ở cả mức toàn cục và cục bộ [7]. Với mô hình Autoencoder (AE) không giám sát, nghiên cứu sử dụng phân rã lỗi tái tạo theo từng biến nhằm xác định đặc trưng gây bất thường chính cho từng giao dịch. Cách tiếp cận kết hợp này giúp giảm tính “hộp đen”, hỗ trợ hậu kiểm và phù hợp yêu cầu minh bạch theo Thông tư 27/2025/TT-NHNN.

E. Logic Mờ trong tính điểm rủi ro

Logic mờ xử lý hiệu quả sự không chắc chắn và không chính xác vốn có trong phát hiện gian lận. Bằng cách định nghĩa các biến ngôn ngữ (ví dụ: “Rủi ro Cao”, “Rủi ro Trung bình”) và các hàm thành viên, các hệ thống suy diễn mờ (như Mamdani) có thể tổng hợp nhiều tín hiệu thành điểm rủi ro nhất quán, mô phỏng lý luận chuyên gia [8].

III. CƠ SỞ LÝ THUYẾT

A. LightGBM và SMOTENC

Hệ thống tiến hành trích xuất bảy đặc trưng cốt lõi từ dữ liệu giao dịch: step, type, amount, oldbalanceOrg, newbalanceOrig, oldbalanceDest, newbalanceDest. Đặc thù của dữ liệu gian lận tài chính là sự mất cân bằng lớp cực kỳ nghiêm trọng (gian lận chỉ chiếm 0.2965%). Để khắc phục vấn đề này, áp dụng kỹ thuật SMOTENC (Synthetic Minority Over-sampling Technique for Nominal and Continuous) cho tập huấn luyện.

Đối với các đặc trưng liên tục (như số tiền, số dư), SMOTENC tạo ra các mẫu thiểu số nhân tạo x_{new} bằng cách nội suy tuyến tính giữa một mẫu thiểu số hiện có x_i và một trong k điểm lân cận gần nhất của nó (x_{knn}):

$$x_{new} = x_i + \lambda \times (x_{knn} - x_i)$$

(Trong đó λ là một số ngẫu nhiên trong khoảng $[0, 1]$). Đối với các đặc trưng phân loại (như type), thuật toán sẽ lấy giá trị xuất hiện nhiều nhất (mode) trong số các điểm lân cận.

Tiến hành thử nghiệm (grid search) đánh giá cả XGBoost và LightGBM trên nhiều tỉ lệ SMOTENC khác nhau. Trong đó, mô hình LightGBM được tối ưu hóa dựa trên hàm mất mát logarit nhị phân (Binary Log-loss). Với tập dữ liệu gồm N mẫu, $y_i \in \{0,1\}$ là nhãn thực tế và p_i là xác suất dự đoán giao dịch là gian lận, hàm mục tiêu được định nghĩa là:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

Để tránh hiện tượng học vẹt (overfitting), quá trình huấn luyện sử dụng cơ chế dừng sớm (early stopping) sau 20 vòng lặp không có sự cải thiện.

Thay vì sử dụng độ chính xác (Accuracy) - vốn bị sai lệch nghiêm trọng trên dữ liệu mất cân bằng, hiệu suất mô hình được đánh giá toàn diện thông qua Diện tích Dưới Đường Cong Precision-Recall (PR-AUC). Các chỉ số Precision ($\mathcal{P}$) và Recall ($\mathcal{R}$) được tính toán như sau:

$$\mathcal{P} = \frac{TP}{TP + FP} \quad ; \quad \mathcal{R} = \frac{TP}{TP + FN}$$

(Với TP , FP , FN lần lượt là True Positives, False Positives, và False Negatives).

Từ đó, chỉ số PR-AUC được tính bằng tích phân của Precision theo Recall:

$$\text{PR-AUC} = \int_0^1 \mathcal{P}(\mathcal{R}) d\mathcal{R}$$

Kết quả thực nghiệm cho thấy LightGBM kết hợp với SMOTENC ở tỉ lệ 0.20 cho ra chỉ số PR-AUC tối ưu nhất, cân bằng hoàn hảo giữa khả năng phát hiện gian lận và việc giảm thiểu tỉ lệ báo động giả (False Alarm Rate).

B. Mạng học sâu vô giám sát Autoencoder

Để bổ trợ cho mô hình học có giám sát và phát hiện các hành vi gian lận mới (zero-day fraud typologies), hệ thống tích hợp một mô hình mạng nơ-ron mã hóa (Autoencoder). Autoencoder được huấn luyện hoàn toàn dựa trên cơ chế học không giám sát (unsupervised learning) với 2.646.646 mẫu giao dịch hợp lệ (normal transactions), giúp mạng nơ-ron học được không gian biểu diễn (manifold) của các hành vi giao dịch thông thường.

Mô hình sử dụng 11 đặc trưng đầu vào đã qua biến đổi logarit để giảm độ lệch (skewness). Một trong những nhóm đặc trưng quan trọng nhất được tạo ra là "sai số số dư" (balance errors), phản ánh sự bất hợp lý giữa số dư trước, số tiền giao dịch và số dư sau. Biểu hình là sai số số dư của người gửi (e_{orig}), được định nghĩa bằng công thức:

$$e_{orig} = new_bal_orig + amount - old_bal_orig$$

Kiến trúc mạng là một mạng truyền thẳng sâu (Deep Feedforward Network) đối xứng với cấu trúc nén và giải nén là: $11 \rightarrow 16 \rightarrow [4] \rightarrow 16 \rightarrow 11$. Nút thắt cổ chai ở giữa chứa 4 nơ-ron, ép mô hình phải nén thông tin cốt lõi nhất. Nghiên cứu này sử dụng hàm kích hoạt SELU (Scaled Exponential Linear Unit) và kỹ thuật điều chuẩn L2 (chuẩn mực $1e-4$) để tránh quá khớp, đồng thời hoàn toàn không sử dụng Dropout để duy trì tính bất định của quá trình tái tạo.

Khi một giao dịch mới đi qua Autoencoder, hệ thống sẽ tính toán Lỗi tái tạo (Reconstruction Error) dưới dạng Trung bình bình phương sai số (Mean Squared Error - MSE) giữa vector đầu vào ban đầu x (có d chiều) và vector được tái tạo $\hat{x}$:

$$MSE = \frac{1}{d} \sum_{j=1}^d (x_j - \hat{x}_j)^2$$

Vì mô hình chỉ được huấn luyện trên dữ liệu bình thường, các giao dịch gian lận mang hành vi lạ sẽ không thể được tái tạo chính xác, dẫn đến giá trị MSE tăng vọt. Kết quả thực nghiệm xác nhận điều này khi Tỷ lệ phân tách (Separation Ratio) của Autoencoder đạt tới 325.21 lần (Trung bình MSE của gian lận là 1.090205 so với mức chỉ 0.003352 của giao dịch bình thường).

Để kết hợp chỉ số này vào hệ thống chấm điểm rủi ro chung (Risk Scoring), giá trị MSE được chuẩn hóa thành Điểm bất thường (Anomaly Score s_{AE}) nằm trong khoảng $[0, 1]$. Việc chuẩn hóa sử dụng hàm logarit nhằm kìm hãm các giá trị ngoại lai (outliers) quá lớn, với công thức chặn (clip) như sau:

$$s_{AE} = \text{clip}\left(\frac{\log(1 + MSE)}{5.0}, 0, 1\right)$$

(Trong đó, hàm clip giới hạn giá trị đầu ra không vượt quá 1 và không nhỏ hơn 0, hằng số 5.0 là hệ số thực nghiệm để hiệu chỉnh phân phối điểm số).

Tín hiệu s_{AE} này sau đó được chuyển tiếp như một bộ khuếch đại độc lập (amplifier) vào tầng Logic mờ (Fuzzy Logic), kết hợp cùng xác suất dự đoán từ LightGBM để ra quyết định cuối cùng.

C. Logic Mờ (Fuzzy Logic)

Tầng cuối cùng của hệ thống chịu trách nhiệm dung hợp (fusion) hai luồng tín hiệu: Xác suất dự đoán có giám sát từ LightGBM (p_{LGBM}) và Điểm bất thường không giám sát từ Autoencoder (s_{AE}). Vì bản chất của các giao dịch gian lận luôn chứa đựng sự mơ hồ và tính bất định cao, Nghiên cứu này áp dụng Hệ thống suy luận mờ Mamdani (Mamdani Fuzzy Inference System) nhằm phản ánh quy trình đánh giá rủi ro trong thực tiễn nghiệp vụ AML.

Quá trình mờ hóa (Fuzzification) biến đổi các giá trị rõ (crisp inputs) p_{LGBM} và s_{AE} thành các tập mờ thông qua các hàm liên thuộc (Membership Functions). Để tối ưu hóa độ nhạy quanh ngưỡng quyết định tối ưu của LightGBM ($\theta_{LGBM} = 0.8504$), hệ thống thiết kế các tập mờ sử dụng kết hợp hàm liên thuộc hình tam giác (Triangular) và hình thang (Trapezoidal).

Hàm liên thuộc hình tam giác μ_{tri} cho một giá trị đầu vào x với ba tham số (a, b, c) được định nghĩa như sau:

$$\mu_{tri}(x; a, b, c) = \max\left(\min\left(\frac{x-a}{b-a}, \frac{c-x}{c-b}\right), 0\right)$$

Đối với các biên của tập giá trị (rất thấp hoặc rất cao), hệ thống sử dụng hàm liên thuộc hình thang μ_{trap} với bốn tham số (a, b, c, d) để duy trì mức độ tin cậy tuyệt đối tại các vùng cận biên:

$$\mu_{trap}(x; a, b, c, d) = \max\left(\min\left(\frac{x-a}{b-a}, 1, \frac{d-x}{d-c}\right), 0\right)$$

Dựa trên các biến ngôn ngữ (Linguistic variables) như "Thấp", "Trung bình", "Cao", hệ thống xây dựng tập hợp gồm 9 luật mờ (Fuzzy Rules). Trọng tâm của bộ luật này đặt p_{LGBM} làm tín hiệu dự báo chính (Primary signal) và s_{AE} đóng vai trò là bộ khuếch đại rủi ro (Amplifier). Ví dụ: Nếu tín hiệu LightGBM là *Trung bình* nhưng Autoencoder phát hiện bất thường *Cao*, mức cảnh báo mờ đầu ra sẽ được đẩy lên *Cao*.

Sau quá trình giải mờ (Defuzzification), hệ thống thu được điểm rủi ro tổng hợp từ mô hình học máy học (gọi là C_1). Để tuân thủ nghiêm ngặt Thông tư 27/2025/TT-NHNN (Điều 3, Khoản 4c) về Đánh giá mức độ rủi ro rửa tiền, điểm C_1 được kết hợp với các tiêu chí định lượng khác để tính ra Điểm rủi ro cuối cùng $R \in [1,5]$. Công thức tính điểm rủi ro tổng thể hệ thống được áp dụng phương pháp tổng có trọng số:

$$R = \frac{\sum_{i=1}^n (C_i \times w_i)}{100}$$

Trong đó, tập hợp các tiêu chí C_i và trọng số w_i được phân bổ theo quy định nghiệp vụ: Rủi ro từ mô hình AI (C_1 , trọng số 30%), Rủi ro Giá trị giao dịch (C_2 , trọng số 20%), Rủi ro Hồ sơ Khách hàng (C_3 , trọng số 25%), Rủi ro Vị trí địa lý (C_4 , trọng số 15%), và Rủi ro Loại hình sản phẩm (C_5 , trọng số 10%). Mức điểm R cuối cùng sẽ phân loại giao dịch vào 1 trong 5 cấp độ rủi ro, làm cơ sở tự động phê duyệt (Auto-Approve), đưa vào hàng đợi đánh giá thủ công (Manual Review), hoặc tự động từ chối (Auto-Reject).

IV. KIẾN TRÚC HỆ THỐNG

A. Kiến trúc hệ thống tổng thể (System Architecture)


Hệ thống ML-ADAS được thiết kế theo mô hình kiến trúc vi dịch vụ, nhằm đảm bảo tính cô lập nghiệp vụ, khả năng mở rộng linh hoạt (scalability) và tốc độ xử lý thời gian thực. Hệ thống được phân rã thành ba phân hệ độc lập:

1. Phân hệ Giao diện Quản trị (Frontend ReactJS): Xây dựng trên nền tảng React 19 và Vite 7, kết hợp quản lý trạng thái qua Redux Toolkit và RTK Query. Phân hệ này cung cấp không gian làm việc (Dashboard) trực quan cho các chuyên viên tuân thủ (Compliance Officers) để theo dõi và điều tra các cảnh báo gian lận.
2. Phân hệ Định tuyến và Xác thực (Backend NodeJS): Phát triển bằng Node.js với Express 5, đóng vai trò như một API Gateway. Phân hệ này xử lý cơ chế định danh JWT, kiểm soát quyền truy cập dựa trên vai trò (RBAC) sử dụng cơ sở dữ liệu MySQL, đồng thời tích hợp SSO và IAM.
3. Phân hệ Lỗi Phân tích Trí tuệ Nhân tạo (Backend Python): Được triển khai bằng FastAPI (Python) nhằm tận dụng kiến trúc xử lý bất đồng bộ (Asynchronous I/O). Đây là nơi thực thi toàn bộ pipeline sàng lọc AML, đồng thời tương tác với cơ sở dữ liệu PostgreSQL chuyên biệt để lưu trữ lịch sử phân tích.

B. Pipeline Sàng lọc Giao dịch Đa tầng (Multi-Layer Screening Pipeline)

Để đảm bảo sự cân bằng giữa tính tuân thủ pháp lý và khả năng phát hiện gian lận tinh vi, mỗi yêu cầu phân tích giao dịch được hệ thống xử lý qua một luồng (pipeline) gồm 4 giai đoạn nối tiếp có tính kế thừa:


Giai đoạn 0: Tiền xử lý dữ liệu (Preprocessing) Dữ liệu đầu vào sau khi qua lớp bảo mật JWT được chuẩn hóa. Nhằm khắc phục tính chất lệch phải đặc trưng của dữ liệu phân phối tài chính, phép biến đổi Logarit $f(x)=\log(1+x)$ được áp dụng lên các biến số tiền và số dư. Cải tiến này giảm hiện tượng nhạy cảm quá mức với các giao dịch có giá trị lớn nhưng hợp lệ, góp phần kéo giảm tỷ lệ báo động giả (FAR) của hệ thống.



Hình 1. Kiến trúc luồng tiếp nhận, xác thực và tiền xử lý dữ liệu

Tầng 1: Động cơ Đối soát Pháp lý cơ sở (Statutory Rules Engine) Tầng này vận hành trên cơ chế tất định, thực thi song song các quy tắc bắt buộc theo luật định của Việt Nam:

- Kiểm tra danh sách đen: Đối khớp mã định danh và đối khớp mở tên khách hàng dựa trên định nghĩa về danh sách đen và danh sách cảnh báo tại Khoản 9 và Khoản 10, Điều 3, Luật 14/2022/QH15. Hệ thống tuân thủ yêu cầu bắt buộc trang bị phần mềm quét lọc danh sách đen theo Điểm b Khoản 1 Điều 10 Thông tư 27/2025/TT-NHNN. Khi phát hiện trùng khớp, hệ thống kích hoạt cơ chế fail-fast: ngay lập tức chặn giao dịch (BLOCK) theo quy định tại Điều 44 Luật 14/2022/QH15, từ chối thực hiện các tầng kiểm tra tiếp theo nhằm tiết kiệm tài nguyên.
- Cảnh báo giao dịch vượt ngưỡng: Tự động nhận diện và gắn cờ các giao dịch cần báo cáo theo quy định pháp luật. Cụ thể, đối với báo cáo giao dịch có giá trị lớn (CTR) áp dụng cho giao dịch tiền mặt từ 400 triệu VNĐ trở lên, hệ thống tự động cảnh báo dựa trên tiêu chuẩn tại Điều 25 Luật 14/2022/QH15 và Điều 6 Thông tư 27/2025/TT-NHNN. Đối với báo cáo giao dịch chuyển tiền điện tử (EFT) áp dụng cho giao dịch trong nước từ 500 triệu VNĐ trở lên, hệ thống tuân thủ tuyệt đối theo Điều 34 Luật 14/2022/QH15 và Điểm a Khoản 1 Điều 9 Thông tư 27/2025/TT-NHNN.




Hình 2. Sơ đồ khối Lớp 1 – Động cơ sàng lọc giao dịch dựa trên quy tắc pháp định (Rule-Based Alert Engine)

Chỉ áp dụng cho các luồng giao dịch mang rủi ro chuyển dịch tài sản cao (TRANSFER và CASH_OUT).

Mô hình có giám sát (LightGBM + SMOTENC): Xử lý 7 đặc trưng (step, type, amount, oldbalanceOrg, newbalanceOrig, oldbalanceDest, newbalanceDest). Ngưỡng quyết định được tinh chỉnh tại giá trị tối ưu $\theta_{LGBM}=0.8504$. Tại ngưỡng này, mô hình đạt độ chính xác 99,48%, độ phủ 80,07%, và tỷ lệ báo động giả 0,0112%.

Mô hình học không giám sát (Deep Autoencoder v2.2): Với cấu trúc nút thắt (Bottleneck = 4), mạng được huấn luyện chuyên biệt trên tập dữ liệu giao dịch bình thường. Giao dịch có hành vi bất thường được phát hiện qua lỗi tái tạo (MSE). Phiên bản này đạt tỷ lệ phân tách (Separation Ratio) 325,21 lần giữa phân phối MSE của gian lận so với giao dịch bình thường.

Cơ chế hợp nhất mờ (Fuzzy Ensemble): Áp dụng 9 luật Mamdani. LightGBM đóng vai trò tín hiệu chính, Autoencoder đóng vai trò kiểm tra bổ sung. Nếu LightGBM chưa rõ ràng (Medium) nhưng Autoencoder phát hiện bất thường lớn (High), hệ thống nâng mức rủi ro lên Cao, giảm nguy cơ bỏ lọt các giao dịch bất thường chưa từng xuất hiện trong dữ liệu huấn luyện.




Hình 3. Sơ đồ khối Lớp 2 – Bộ tổng hợp suy diễn Học máy (ML Scoring Engine)

Tầng 3: Động cơ Đánh giá Rủi ro Toàn diện (Risk Scoring Engine) Điểm rủi ro cuối cùng được tổng hợp qua công thức trọng số tuân thủ Điều 3, Khoản 4c, Thông tư 27/2025/TT-NHNN:

$$R = \frac{1}{100} \sum_{i=1}^5 (C_i \times w_i)$$

Với các trọng số phân bổ: ML probability từ AI (C_1: 30%), Quy mô và loại giao dịch (C_2: 20%), Cấp độ rủi ro khách hàng KYC (C_3: 25%), Rủi ro ranh giới địa lý theo FATF (C_4: 15%), Bản chất sản phẩm dịch vụ (C_5: 10%).

Điểm số đầu ra dao động từ 1 đến 5, phân thành 5 cấp độ: Thấp, Trung bình thấp, Trung bình, Trung bình cao, Cao. Cấp độ Cao kích hoạt biện pháp can thiệp tự động (chặn hoặc đưa vào kiểm duyệt thủ công).




Hình 4. Sơ đồ khối Lớp 3 – Hệ thống giám sát và tổng hợp điểm rủi ro giao dịch

C. Module khả năng giải thích (XAI)

Nhằm giải quyết tính hộp đen của hệ thống và đáp ứng yêu cầu minh bạch giải trình tại Điều 3, Khoản 4d Thông tư 27/2025, ngay sau khi Tầng 3 ra quyết định, hệ thống sinh nội dung giải thích qua 3 cơ chế:

- SHAP Values: Sử dụng shap.TreeExplorer, định lượng hóa mức đóng góp cục bộ của từng tham số. Kết quả phân tích toàn cục cho thấy oldbalanceOrg, amount và step là 3 yếu tố mang lượng thông tin và tác động SHAP lớn nhất vào quyết định chặn giao dịch.
- AE Per-feature Reconstruction Error: Tính toán lỗi MSE trên từng tham số đầu vào. Điều này hỗ trợ kiểm toán viên xác định cột dữ liệu nào gây ra dị biệt. Trung bình lỗi tái tạo của giao dịch hợp lệ chỉ 0,003352, trong khi của gian lận tăng vọt lên 1,090205.
- LLM Narrative Generation: Sử dụng mô hình ngôn ngữ lớn qua Groq API, áp dụng kỹ thuật Zero-shot Contextual Prompting bằng tiếng Việt để tự động phiên dịch ma trận số liệu thành văn bản có cấu trúc ngôn ngữ tự nhiên. Hệ thống thiết kế cơ chế fail-soft: nếu LLM phản hồi chậm hoặc lỗi, tính năng diễn giải trả về trạng thái không khả dụng, không làm gián đoạn luồng xử lý chính.



Hình 5. Cấu trúc phân hệ Trí tuệ nhân tạo có thể giải thích (XAI - Explainability Module)


V. TẬP DỮ LIỆU VÀ THIẾT LẬP THỰC NGHIỆM

A. Tập dữ liệu Paysim


Sử dụng tập dữ liệu PaySim, một tập dữ liệu tài chính tổng hợp mô phỏng các giao dịch tiền di động dựa trên nhật ký thực tế từ một quốc gia châu Phi [9]. Để phản ánh các kịch bản AML rủi ro cao, Nghiên cứu này lọc tập dữ liệu chỉ bao gồm các loại giao dịch TRANSFER và CASH_OUT.

B. Chia dữ liệu mất cân bằng


Tập dữ liệu được lọc thể hiện sự mất cân bằng lớp cực độ. Như minh họa trong Hình 6, các giao dịch gian lận chiếm một tỉ lệ rất nhỏ. Nghiên cứu này thực hiện chia tách dựa trên thời gian sử dụng đặc trưng step (trong đó 1 step = 1 giờ) để ngăn rò rỉ dữ liệu theo thời gian, như được trình bày trong Hình 7 (LGBM), Hình 8 (AE). Thống kê chia tách được trình bày chi tiết trong Bảng 1.Bảng 1 (LGBM) Bảng 1.Bảng 2 (AE).



Hình 6. Mất cân bằng lớp cực độ trong tập dữ liệu PaySim được lọc. Giao dịch gian lận chỉ chiếm 0,2965% tổng số



Hình 7. Phân phối dữ liệu các tập Huấn luyện, Xác thực và Kiểm tra của mô hình LightGBM (trước khi áp dụng SMOTENC)



Hình 8. Phân phối dữ liệu các tập Huấn luyện, Xác thực và Kiểm tra của mô hình Autoencoder (chỉ huấn luyện trên dữ liệu bình thường)

Bảng 1. Thống Kê Tập Dữ Liệu và Phân Chia LGBM

Phân chia	Tổng	Bình thường	Gian lận	Gian lận %
Huấn luyện (≤500)	2.645.779	2.640.218	5.561	0,2102%
Xác thực (501–550)	42.409	41.905	504	1,1884%
Kiểm tra (>550)	82.221	80.073	2.148	2,6125%
Tổng cộng	2.770.409	2.762.196	8.213	0,2965%

Bảng 2. Thống Kê Tập Dữ Liệu và Phân Chia AE

Phân chia	Tổng	Bình thường	Gian lận	Gian lận %
Huấn luyện (1–518, normal-only)	2.646.646	2.646.646	0	0,0000%
Xác thực (520–594)	66.708	65.918	790	1,1843%
Kiểm tra (595–743)	51.286	49.632	1.654	3,2251%
Tổng cộng	2.764.640	2.762.196	2.444	0,0884%

VI. THỰC NGHIỆM VÀ KẾT QUẢ

A. Quét SMOTENC và lựa chọn mô hình


Bảng 3 trình bày kết quả tìm kiếm lưới toàn diện qua các mô hình và tỉ lệ lấy mẫu. Nghiên cứu này đo hiệu suất bằng PR-AUC, F1-Score và Tỷ lệ Cảnh báo Nhầm (FAR), được định nghĩa như Phương trình:

$$FAR = \frac{FP}{FP + TN}$$

Bảng 3. So Sánh Hiệu Suất Các Mô Hình Có Giám Sát (Quét SMOTENC)

Mô hình	Tỉ lệ Val	PR-AUC (Val)	PR-AUC (Test)	Test F1	Test Recall	Test Prec.	Test FAR	Ngưỡng
XGBoost	0,10	0,9845	0,9895	0,8842	0,7984	0,9908	0,0200%	0,5118
LightGBM	0,10	0,9846	0,9922	0,8862	0,8012	0,9914	0,0187%	0,7926
XGBoost	0,20	0,9816	0,9888	0,8873	0,8012	0,9942	0,0125%	0,5826
LightGBM	0,20	0,9859	0,9915	0,8873	0,8007	0,9948	0,0112%	0,8504
XGBoost	0,33	0,9798	0,9886	0,8824	0,7928	0,9947	0,0112%	0,6938
LightGBM	0,33	0,9842	0,9909	0,8951	0,8161	0,9910	0,0200%	0,8381
XGBoost	0,50	0,9811	0,9887	0,8869	0,7998	0,9954	0,0100%	0,6598
LightGBM	0,50	0,9836	0,9897	0,8817	0,7914	0,9953	0,0100%	0,9218
XGBoost	1,00	0,9766	0,9868	0,8773	0,7854	0,9935	0,0137%	0,8122
LightGBM	1,00	0,9799	0,9876	0,8855	0,8007	0,9902	0,0212%	0,9529

Kết quả quét cho thấy LightGBM tỉ lệ 0,20 là cấu hình tối ưu, đạt Val PR-AUC cao nhất (0,9859) trong khi duy trì FAR cực thấp (0,0112%). Hình 9 trực quan hóa quá trình đánh đổi này.



Hình 9. So sánh Validation PR-AUC và Test False Alarm Rate (FAR) theo tỉ lệ SMOTENC của XGBoost và LightGBM.

B. Hiệu suất mô hình

Mô hình LightGBM được chọn thể hiện độ bền vững xuất sắc (Bảng 4). Điểm Brier thấp (0,00249) cho thấy hiệu chỉnh xác suất xuất sắc. Đường cong PR trên tập kiểm tra đạt diện tích 0,9915.

Bảng 4. Chỉ Số Chi Tiết LightGBM


Chỉ Số	Giá Trị
PR-AUC	0,9915
Precision	0,9948
Recall	0,8007
F1-Score	0,8873
Tỷ lệ Cảnh báo Nhầm (FAR)	0,0112%
Điểm Brier	0,002490
Ngưỡng Tối ưu	0,8504

C. Kết quả Autoencoder

Được huấn luyện qua 150 epoch, AE thành công ánh xạ đa tạp của các giao dịch bình thường. Mô hình đạt tỉ lệ phân tách **325,21 lần** giữa MSE trung bình của gian lận (1,090) và bình thường (0,0033) — Bảng 5. Hình 10 cho thấy các phân phối MSE hoàn toàn tách biệt.

Bảng 5. Chỉ Số Autoencoder

Chỉ Số Autoencoder	Giá Trị
AUROC	0,9996
PR-AUC	0,9842
Tỉ lệ Phân Tách	325,21×
FAR tại ngưỡng mặc định	0,0947%
MSE trung bình (Bình thường)	0,003352
MSE trung bình (Gian lận)	1,090205
Loss Xác thực Cuối	0,0087



Hình 10. Phân phối MSE tái tạo của AE. Hai phân phối hoàn toàn tách biệt, xác nhận tỉ lệ phân tách 325×.

D. Điều chỉnh ngưỡng

Hệ thống hóa điều chỉnh ngưỡng quyết định LightGBM để tối thiểu hóa FAR trong khi duy trì Recall chấp nhận được (Bảng 6). Ngưỡng tối ưu được xác định tại 0,8504. Tại ngưỡng này, ma trận nhầm lẫn cho thấy chỉ 9 dương tính giả trên hơn 80.000 giao dịch bình thường.

Ngoại suy các chỉ số tập kiểm tra sang tải hoạt động hàng ngày mô phỏng (Bảng 7), hệ thống tự động từ chối 196,1 gian lận thực trong khi chỉ gửi 18,7 cảnh báo để xét duyệt thủ công, chứa chỉ 0,9 cảnh báo nhầm mỗi ngày.

Bảng 6. Kết Quả Điều Chỉnh Ngưỡng (LightGBM)


Ngưỡng	Precision	Recall	F1	FAR
0,5000	0,9028	0,9860	0,9426	0,2847%
0,7000	0,9590	0,9372	0,9480	0,1074%
0,8504 (Tối ưu)	0,9948	0,8007	0,8873	0,0112%
0,9000	0,9982	0,7663	0,8670	0,0037%
0,9500	0,9987	0,7342	0,8463	0,0025%

Bảng 7. Mô Phỏng Tác Động Kinh (Hàng Ngày)

Giai đoạn	Ngưỡng p	Chỉ số	Giá trị/Ngày
Thiết lập	–	Tổng Giao dịch Gian lận Thực tế	10.224 267
Từ Chối Tự Động	$p \geq 0,95$	Tổng Kích Hoạt Gian lận Bắt được Từ chối Nhầm	196,4 196,1 0,2
Xét Duyệt Thủ Công	$0,85 \leq p < 0,95$	Tổng Cảnh báo Gian lận Thực Cảnh báo Nhầm	18,7 17,8 0,9
Tự Động Duyệt	$p < 0,85$	Tổng Đã Duyệt Bình thường Được Duyệt Gian lận Bỏ Sót	10.009 9.956 53,2

E. Khả năng giải thích

Tầm quan trọng đặc trưng được xác minh sử dụng LightGBM Split Gain so với SHAP Mean $|\phi|$ (Bảng 8). Cả hai phương pháp đều xác nhận oldbalanceOrg, amount và step là các đặc trưng dự đoán chủ đạo. Hình 11 trực quan hóa điểm quan trọng SHAP.




Hình 11. Điểm quan trọng đặc trưng SHAP trung bình $|\phi|$. oldbalanceOrg và amount là các đặc trưng dự đoán nổi bật nhất.

Bảng 8. Tầm Quan Trọng Đặc Trưng (LightGBM Gain vs SHAP)

Đặc trưng	Gain	Xếp hạng (Gain)	SHAP Mean	Xếp hạng (SHAP)
oldbalanceOrg	2.493	1	2,697	1
amount	2.333	2	1,375	2
step	1.663	3	1,339	3
newbalanceOrig	425	6	1,144	4
oldbalanceDest	798	5	0,392	5
type	353	7	0,375	6
newbalanceDest	935	4	0,371	7

Tầm quan trọng đặc trưng cho Autoencoder được xác định qua phân rã lỗi tái tạo theo từng biến (Bảng 9). Với mỗi giao dịch, AE tính sai số tái tạo từng đặc trưng: nếu đặc trưng có lỗi cao khi so sánh Fraud vs Normal, đó là đặc trưng quan trọng nhất cho việc phát hiện bất thường.

Cả hai phương pháp (LightGBM/SHAP và AE/per-feature error) đều xác nhận oldbalanceOrg, amount là các đặc trưng dự đoán chủ đạo. Hình 12 trực quan hóa per-feature reconstruction error theo lớp.



Hình 12. Per-Feature Reconstruction Error (Phân rã lỗi tái tạo AE theo lớp)

Bảng 9. Per-Feature Reconstruction Error (AE - Normal vs Fraud)

Đặc trưng	Normal MSE Trung bình	Fraud MSE Trung bình	Tỷ lệ (Fraud/Normal)
type	0,0006	3,0160	5.101,91×
log_newbalanceOrig	0,0091	2,7926	306,13×
log_amount	0,0016	1,7837	1.100,69×
log_errorBalanceOrig	0,0075	1,3317	177,26×
log_oldbalanceDest	0,0006	1,3207	2.100,57×
balance_drain	0,0086	0,9219	107,44×
log_errorBalanceDest	0,0012	0,4667	396,52×
log_newbalanceDest	0,0008	0,2177	263,07×
amount_ratio	0,0026	0,0649	24,97×
dest_no_receive	0,0002	0,0407	193,49×
log_oldbalanceOrig	0,0040	0,0356	8,90×

VII. KẾT LUẬN

Nghiên cứu này đã trình bày ML-ADAS, một hệ thống sàng lọc giao dịch AML ba lớp tích hợp quy tắc pháp định tất định, học máy hai tín hiệu và logic mờ Mamdani. Được đánh giá trên tập dữ liệu PaySim bất cân bằng cao (tỉ lệ gian lận 0,2965%), hệ thống đạt các kết quả nổi bật: mô hình LightGBM với SMOTENC tỉ lệ 0,20 đạt PR-AUC 0,9915 và FAR cực thấp 0,0112% trên tập kiểm tra; Autoencoder v2.2 đạt tỉ lệ phân tách 325,21 lần giữa lỗi tái tạo của giao dịch bình thường và gian lận. Mô phỏng triển khai thực tế cho thấy hệ thống có thể tự động xử lý trên 97% giao dịch (từ chối tức thì hoặc phê duyệt tự động), chi chuyển khoảng 18,7 trường hợp mỗi ngày vào hàng đợi xét duyệt thủ công, qua đó giảm đáng kể gánh nặng điều tra trong khi vẫn đảm bảo tuân thủ Luật 14/2022/QH15 và Thông tư 27/2025/TT-NHNN.

Tuy nhiên, nghiên cứu còn một số hạn chế cần lưu ý. Tập dữ liệu PaySim là dữ liệu tổng hợp, chưa phản ánh đầy đủ sự phức tạp của giao dịch thực tế trong hệ thống ngân hàng Việt Nam. Ngoài ra, bộ luật mờ hiện tại được xây dựng dựa trên tri thức chuyên gia, có thể cần hiệu chỉnh khi triển khai thực tế. Các hướng nghiên cứu tiếp theo bao gồm: kiểm nghiệm hệ thống trên dữ liệu giao dịch thực của ngân hàng Việt Nam; tích hợp các đặc trưng đồ thị (Graph Neural Networks) để phát hiện mạng lưới rửa tiền phức tạp; và tự động hóa quá trình tối ưu hóa tham số logic mờ thông qua học tăng cường.

VIII. TÀI LIỆU THAM KHẢO

[1] Quốc hội Việt Nam, “Luật Phòng chống Rửa tiền”, Luật số 14/2022/QH15, Quốc hội CHXHCN Việt Nam, Hà Nội, 2022

[2] Ngân hàng Nhà nước Việt Nam, “Thông tư Hướng dẫn Phòng chống Rửa tiền,” Thông tư 27/2025/TT-NHNN, 2025.

[3] T. Chen và C. Guestrin, “XGBoost: Hệ thống tăng cường cây có thể mở rộng,” trong Kỷ yếu Hội nghị Quốc tế ACM SIGKDD lần thứ 22, 2016, tr. 785–794

[4] G. Ke và cộng sự, “LightGBM: Cây quyết định tăng cường gradient hiệu quả cao,” Tiến bộ trong Hệ thống Xử lý Thông tin Nơ-ron, tập 30, 2017.

[5] N. V. Chawla và cộng sự, “SMOTE: Kỹ thuật lấy mẫu vượt trội thiểu số tổng hợp,” Tạp chí Nghiên cứu Trí tuệ Nhân tạo, tập 16, tr. 321–357, 2002.

[6] G. Pang và cộng sự, “Học sâu cho phát hiện bất thường: Một đánh giá,” Khảo sát Điện toán ACM, tập 54, số 2, tr. 1–38, 2021.

[7] S. M. Lundberg và S.-I. Lee, “Phương pháp thống nhất để diễn giải dự đoán mô hình,” Tiến bộ trong Hệ thống Xử lý Thông tin Nơ-ron, tập 30, 2017.

[8] L. A. Zadeh, “Tập mờ,” Thông tin và Điều khiển, tập 8, số 3, tr. 338–353, 1965

[9] E. A. Lopez-Rojas và cộng sự, “PaySim: Bộ mô phỏng tiền di động tài chính để phát hiện gian lận,” trong Hội nghị Mô phỏng Mô hình Châu Âu lần thứ 28, 2016.