

CHẨN ĐOÁN UNG THƯ VÚ TRÊN NHỮ ẢNH SỬ DỤNG CÁC MÔ HÌNH HỌC SÂU VÀ MẠNG VISION TRANSFORMER

Tóm tắt – Ung thư vú là loại ung thư được chẩn đoán phổ biến nhất và là nguyên nhân thứ năm gây tử vong ở phụ nữ. Việc phát hiện sớm căn bệnh này không chỉ tăng tỷ lệ sống sót mà còn giảm chi phí điều trị. Chụp nhũ ảnh là phương pháp chẩn đoán hình ảnh hiện nay để xác định và chẩn đoán sớm khối u ác tính ở vú. Trong bài báo này, chúng tôi đề xuất kỹ thuật phân loại dựa trên kiến trúc mạng học sâu như NasNetLarge, MobileNetV2, InceptionV3, DenseNet121 và mạng phân loại Vision Transformer để phân loại ảnh nhũ tuyến vú là bình thường, lành tính hay ác tính. Qua kết quả thực nghiệm cho thấy độ chính xác của mô hình đề xuất lên đến 99%, giải pháp hỗ trợ sàng lọc nhũ ảnh có chứa tổn thương sẽ giúp Bác sĩ tập trung phân tích nhiều hơn kết quả phân loại này. Nhờ đó độ chính xác chẩn đoán tăng lên và đưa ra hướng điều trị kịp thời.

Từ khóa – Vision Transformer, Ung thư vú, Chụp nhũ ảnh, Deep learning, Chẩn đoán ung thư vú

I. GIỚI THIỆU

A. Giới thiệu bài toán

Ung thư vú đã trở thành một trong những dạng ung thư thường xảy ra ở phụ nữ. Ước tính có khoảng 2.261.419 trường hợp ung thư vú mới được chẩn đoán ở phụ nữ trên toàn thế giới vào năm 2020. Vào năm 2023, ước tính có khoảng 297.790 phụ nữ và khoảng 2.800 nam giới ở Hoa Kỳ được chẩn đoán mắc bệnh ung thư vú xâm lấn và 55.720 phụ nữ sẽ được chẩn đoán mắc bệnh ung thư vú không xâm lấn. Người ta ước tính rằng 43.700 ca tử vong (43.170 phụ nữ và 530 nam giới) do ung thư vú sẽ xảy ra ở Hoa Kỳ vào năm 2023. Trên toàn thế giới, ung thư vú ở phụ nữ là nguyên nhân gây tử vong đứng hàng thứ năm. Năm 2020, ước tính có khoảng 684.996 phụ nữ trên toàn thế giới chết vì ung thư vú.[15]. Trong thực hành lâm sàng, chụp nhũ ảnh là một công cụ chẩn đoán được sử dụng rộng rãi để sàng lọc ung thư vú [1]. Chụp nhũ ảnh đòi hỏi phải để ngực của bệnh nhân tiếp xúc với bức xạ tia X ở mức độ thấp. Ung thư vú có thể xác định được từ chụp quang tuyến vú nhờ tỷ lệ hấp thụ tia X khác nhau của các mô bình thường và bất thường. Các khối u có thể xuất hiện dưới dạng khối, biến dạng, không đối xứng, khối lượng suy đoán hoặc vi vôi hóa trên chụp quang tuyến vú [2]. Để phát hiện và chẩn đoán chính xác ung thư vú (nghĩa là bình thường và bất thường), các bác sĩ phải đối mặt với những thách thức do họ phải kiểm tra số lượng lớn hình ảnh vú hàng ngày và khó đọc hình ảnh (nghĩa là phát hiện khối u ở vú và chẩn đoán chính xác chúng) [3]. Việc xây dựng một hệ thống hỗ trợ việc chẩn đoán ung thư vú nhằm tạo nhiều thuận lợi hơn cho các bác sĩ trong quá trình phân tích và chẩn đoán thông qua hình ảnh nhũ để có giải pháp điều trị kịp thời vô cùng cần thiết.

B. Những nghiên cứu liên quan


S. Shamy và cộng sự. [16] đã đề xuất mô hình dựa trên k-mean GMM và CNN. Đầu tiên tác giả tìm hiểu ROI và sau đó áp dụng phương pháp trích xuất đặc trưng kết cấu. Độ chính xác mà tác giả đạt được là 95,8%. V Sansya Vijayam và cộng sự. [17] đã đề xuất mô hình dựa trên học sâu. Tác giả tập trung vào thuật toán của Lloyd để phân cụm và CNN để phân loại. Độ chính xác 96% đã đạt được bằng các phương pháp được đề xuất. Varsha J. Gaikwad và cộng sự [18] đã đề xuất mô hình dựa trên chụp quang tuyến vú sử dụng bộ phân loại SVM. Đầu tiên là tiền xử lý, phân đoạn trích xuất ROI, trích xuất và phân loại tính năng, hệ thống đề xuất đạt được độ chính xác 83%. Muhammad Aaqib và cộng sự [19] đã đề xuất phương pháp xác định bệnh ung thư vú dựa trên bộ dữ liệu kỹ thuật số để sàng lọc nhũ ảnh (DDSM) chứa 2620 trường hợp chụp quang tuyến vú đã được kết hợp để thử nghiệm và sử dụng mạng VGG-16 để trích xuất tính năng, SSD được tích hợp để phát hiện khối u, kết quả cho thấy độ chính xác là 96,2%. Hiba Chougrad và cộng sự [20] đã đề xuất một hệ thống sử dụng mạng CNN để phát hiện ung thư vú từ hình ảnh siêu âm. Kết quả cho thấy phương pháp này đạt được độ chính xác lên đến 98% và có thể giúp cải thiện quá trình sàng lọc ung thư vú. Ziliang Zhong và cộng sự [21] đã đề xuất một mô hình phân loại hình ảnh ung thư di căn mới dựa trên DenseNet Block, mô hình này có thể xác định hiệu quả ung thư di căn trong các mảng hình ảnh nhỏ được lấy từ các lần quét bệnh lý kỹ thuật số lớn hơn. Độ chính xác của mô hình đề xuất trong quá trình huấn luyện lên đến 98%. Dheeb Albashish và cộng sự [22] đề xuất một mô hình học chuyển đổi dựa trên mạng VGG16 được sử dụng để trích xuất các tính năng từ bộ dữ liệu hình ảnh mô bệnh học của BreakHis. Độ chính xác của mô hình đề xuất là 89%. Gayathri Girish và cộng sự [23] đề xuất mô hình phát hiện ung thư vú dựa trên hình ảnh microwave với 7 kiến trúc mạng học sâu khác nhau; kết quả của phương pháp đề xuất đạt được độ chính xác là 88.41%. Md Ishtyaq Mahmud và cộng sự [24] trình bày phương pháp phát hiện ung thư vú sử dụng các hình ảnh mô bệnh học sử dụng phương pháp học chuyển giao dựa trên các mạng học sâu như ResNet50, ResNet101, VGG16 và VGG19 với độ chính xác đạt được là 90,2%. Bitu Asadi và cộng sự [25] đề xuất mô hình phát hiện ung thư vú dựa trên kiến trúc mạng Unet với backbone ResNet sử dụng tập dữ liệu Image Retrieval trong Medical Application với 736 mẫu sinh thiết của 344 bệnh nhân. Kết quả của phương pháp đề

xuất đạt được độ chính xác là 98.61%.

II. CÁC CÔNG VIỆC LIÊN QUAN

A. Đặc điểm của bệnh ung thư vú

Ung thư vú [26] là một căn bệnh về tế bào ung thư phát triển từ tế bào trong tuyến vú. Có hai loại ung thư vú chính là ung thư vú lành tính và ung thư vú ác tính. Khối u lành tính [26] dùng để chỉ một khối u nằm yên và không lan sang các bộ phận khác của cơ thể. Chúng không lan đến các cấu trúc lân cận hoặc các vùng xa của cơ thể. Các khối u lành tính thường có ranh giới rõ ràng và phát triển chậm. Phần lớn các khối u lành tính là vô hại. Ung thư vú ác tính [26] là một khối u phát triển trong tuyến vú, nhưng có khả năng xâm lấn vào các mô xung quanh và có thể lan sang các phần khác của cơ thể. Chúng thường được quan sát thấy và có thể cần được phẫu thuật cắt bỏ. Sự phân tán cục bộ hoặc toàn cầu của quần thể tế bào khối u ác tính không được kiểm soát và có thể đe dọa đến tính mạng bệnh nhân nếu không điều trị kịp thời.



Hình 1. Hình ảnh (A) lành tính, (B) có tế bào ung thư trích từ bộ dữ liệu kiểm thử [14]

B. Các mô hình mạng dùng trong huấn luyện

1. MobileNetV2

MobileNetV2 [5] là một trong những mạng neural network được phát triển để có thể thực hiện trên các thiết bị có tài nguyên hạn chế với số lượng tham số nhỏ hơn so với các mạng khác như VGG hay ResNet, giúp giảm tải tài nguyên tính toán và bộ nhớ. Với kích thước nhỏ gọn, MobileNetV2 có thể thực hiện tốc độ cao trên các thiết bị có tài nguyên hạn chế và cho phép điều chỉnh kích thước của mô hình để phù hợp với các nhu cầu ứng dụng khác nhau.

2. Mạng InceptionV3

InceptionV3 [4] là một trong những mạng convolutional neural network (CNN) nổi tiếng và được sử dụng rộng rãi trong lĩnh vực thị giác máy tính và xử lý ảnh. InceptionV3 được thiết kế để tối ưu hoá hiệu quả tính toán, giúp giảm thiểu số lượng tham số cần thiết và giảm độ phức tạp tính toán. Điều này giúp tăng tốc độ xử lý và giảm thời gian đào tạo mạng. Ngoài ra, InceptionV3 có khả năng tái sử dụng đặc trưng, tức là các trọng số học được có thể được sử dụng lại cho các tác vụ liên quan đến phân loại hình ảnh khác nhau.

3. Mạng NASNetLarge

NASNetLarge [6] là một mô hình mạng nơ-ron tích chập được tạo ra thông qua quá trình tìm kiếm kiến trúc tự động. Nó có khả năng học và tìm ra kiến trúc mạng tối ưu dựa trên tập dữ liệu huấn luyện. NasNetLarge có khả năng nhận diện đối tượng với độ chính xác cao và tốn ít bộ nhớ trong quá trình huấn luyện.

4. Mạng DenseNet

Dense Convolutional Network (DenseNet) [7] có mật độ kết nối dày đặc so với các mô hình khác như VGG [8] và Resnet [9]. Nó kết hợp các khối mạng gần nhau và chia sẻ thông tin đặc trưng giữa các lớp, giúp tăng khả năng học và giảm số lượng tham số cần tối ưu. Mô hình DenseNet cho phép học được các đặc trưng cấp cao và cấp thấp trong quá trình huấn luyện và thích hợp cho các tác vụ phân loại ảnh và nhận dạng đối tượng. DenseNet có thể giảm bớt vấn đề biến mất độ dốc, nâng cao khả năng lan truyền của bản đồ đặc trưng và giảm số lượng tham số.

5. Mạng Vision Transformer

Vision Transformer [10] là một mạng nơ-ron được sử dụng để xử lý và phân loại hình ảnh dựa trên cơ chế tự chú ý. Nó dựa trên mô hình Transformer ban đầu được sử dụng trong xử lý ngôn ngữ tự nhiên. Trong mô hình này, ảnh được chia thành các patch và được đưa vào Transform Encoder để xử lý và trích xuất đặc trưng của hình ảnh. Cuối

cùng, một lớp phân loại được sử dụng để dự đoán nhãn của hình ảnh. Vision Transformer cho phép xử lý hình ảnh bằng cách chia ảnh thành các patch nhỏ. Điều này giúp mô hình nhận biết các đặc trưng không gian trong ảnh và mối quan hệ giữa các patch; quá trình xử lý thông tin được thực hiện dựa trên các phép chuyển đổi tuyến tính (linear transformation) và cơ chế tự chú ý mà không yêu cầu các phép tích chập (convolution) như các mạng CNN. Ngoài ra, Vision Transformer có thể mở rộng để xử lý ảnh có kích thước lớn hơn bằng cách tăng số lượng patch. Điều này giúp nó xử lý được các ảnh có độ phân giải cao mà không gặp vấn đề về hiệu suất. Với độ phức tạp tính toán thấp và khả năng khắc phục những hạn chế của mạng neural tích chập trong việc xử lý hình ảnh, ViT vượt trội so với một số mô hình mạng CNN tiên tiến nhất hiện nay. [11]

6. Độ đo đánh giá mô hình


Accuracy [12] được đánh giá dựa trên các giá trị như true positives (TP), false positives (FP), true negatives (TN) và false negatives (FN) được mô tả theo phương trình (1). Hàm categorical cross-entropy loss ($L(C, P)$) [13] với i là nhãn dữ liệu, C là giá trị thực tế và P là giá trị dự đoán. Hàm $L(C, P)$ được mô tả theo phương trình (2).

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

$$L(C, P) = - \sum_i C_i \log(P_i) \quad (2)$$

III. PHƯƠNG PHÁP ĐỀ XUẤT

Trong nghiên cứu này, chúng tôi sử dụng phương pháp học chuyển giao dựa trên kỹ thuật học sâu và mạng Vision Transformer để phát hiện và phân loại ung thư vú. Mô hình đề xuất gồm 2 giai đoạn là huấn luyện và kiểm thử. Chi tiết của các giai đoạn được thể hiện ở hình 2



Hình 2. Mô hình đề xuất phát hiện và phân loại ung thư vú

A. Pha huấn luyện


1. Tiền xử lý và chuẩn bị dữ liệu

Chúng tôi thực hiện chuẩn hoá tất cả hình ảnh thành kích thước 224×224 pixel, đây là kích thước phù hợp để tạo bản vá từ hình ảnh đầu vào. Sau đó, chúng tôi tiến hành tăng cường dữ liệu bằng cách thay đổi góc quay hình ảnh (xoay ảnh) và lật ảnh.

2. Rút trích đặc trưng và huấn luyện

Với các ưu điểm của mạng học sâu và mạng phân loại Vision Transformer được trình bày trong phần B, chúng tôi tiến hành rút trích đặc trưng các đặc điểm của các loại ung thư vú dựa trên ảnh nhũ sau khi được tiền xử lý và tiến hành huấn luyện bằng phương pháp học sâu gồm các mô hình NasNetLarge, MobileNetV2, InceptionV3, DenseNet121 và mạng phân loại Vision Transformer. Đối với mô hình Vision Transformer, hình ảnh đầu vào sau khi được tiền xử lý sẽ được cắt thành cách patch đưa qua tầng liner projection. Ở đây chúng tôi chọn kích thước cho mỗi patch là 16×16 do tính ổn định của nó đối với sự suy giảm hiệu suất và tính phức tạp tính toán [11], mỗi patch sẽ được gán vị trí và nhãn cụ thể đảm bảo ảnh sau khi rút trích các đặc trưng sẽ không bị xáo trộn. Sau đó đưa qua transform encoder để tiến hành rút

trích đặc trưng mã hóa, phân loại và khoanh vùng lành tính và ác tính. Trong đó, tầng Layer Norm có chức năng chuẩn hóa đầu vào và cho phép mô hình thích ứng với các biến thể trong các tập train. Tầng Multi-head Attention Network – MSP là mạng đảm nhiệm việc tạo ra các attention maps từ các feature vector. Attention maps giúp mô hình tập trung vào các vùng quan trọng nhất trong hình ảnh, chẳng hạn như đối tượng. Cuối cùng tầng Multi-Layer Perceptrons – MLP, một mạng phân loại hai tầng với activation function GELU (Gaussian Error Linear Unit) ở cuối; Bên cạnh đó tầng MLP head được sử dụng làm đầu ra của transformer với hàm softmax dùng để tạo ra nhãn phân loại. Kết quả của quá trình này sẽ là ảnh được phân loại thuộc vào nhãn nào. Kiến trúc mạng Vision Transformer đề xuất được thể hiện trong hình 3.



Hình 3. Kiến trúc Vision Transformer đề xuất

B. Pha kiểm thử

Để đánh giá độ chính xác của mô hình, chúng tôi tiến hành kiểm thử mô hình vừa đào tạo bằng tập dữ liệu độc lập mà chúng tôi tự xây dựng. Ảnh đầu vào ở giai đoạn kiểm thử sẽ được chuẩn hoá thành kích thích 224 x 224, sau đó tiến hành đưa qua YOLOV7 để xác định vùng nhũ, vùng nhũ khi được xác định sẽ tiến hành đưa qua mô hình đã được huấn luyện để tiến hành dự đoán. Kết quả kiểm thử sẽ đưa ra một trong ba kết luận là Bình thường, Lành tính hoặc Ác tính.

IV. KẾT QUẢ THỰC NGHIỆM

A. Môi trường cài đặt và tập dữ liệu thực nghiệm

1. Môi trường cài đặt

Phương pháp đề xuất được cài đặt trên nền tảng Kaggle với thư viện hỗ trợ đào tạo mô hình mạng sử dụng là Tensorflow và Keras với ngôn ngữ lập trình Python.

2. Tập dữ liệu thực nghiệm

a. Dữ liệu đào tạo: Bộ dữ liệu sử dụng trong nghiên cứu này được lấy từ Mini-MIAS [14] bao gồm 322 hình ảnh chứa hình ảnh vú trái và phải của 161 bệnh nhân thuộc ba loại như bình thường, lành tính và ác tính. Có 208 hình ảnh bình thường, 63 lành tính và 51 hình ảnh ác tính (bất thường).

b. Dữ liệu kiểm thử: Để tiến hành kiểm thử độ chính xác của mô hình đào tạo chúng tôi xây dựng một tập dữ liệu kiểm thử được lấy từ Bệnh viện Phụ sản TP. Cần Thơ với 150 bệnh nhân gồm 300 hình ảnh của các loại khối u gồm 100 ảnh bình thường, 100 lành tính và 100 ác tính.

B. Các kịch bản áp dụng

Để tiến hành thực nghiệm cho mô hình đề xuất, chúng tôi thực hiện 5 kịch bản với các tham số trong Bảng 1

Bảng 1. Các kịch bản được đề xuất và các tham số huấn luyện

Kịch bản	Kiến trúc mạng	Epochs	Learning rate	Image size
1	MobileNetV2	100	1e-3	224 × 224


2	InceptionV3	100	1e-3	224 × 224
3	NasNetLarge	100	1e-3	224 × 224
4	DenseNet121	100	1e-3	224 × 224
5	Vision Transformer	100	1e-3	224 × 224

C. Kết quả huấn luyện

1. Đánh giá mô hình

a. Độ đo Loss của các kịch bản


Hình 4 biểu diễn giá trị mất mát (loss) của các kịch bản trong giai đoạn huấn luyện. Giá trị val loss của các kịch bản lần lượt là kịch bản 1 là 0.8354, kịch bản 2 là 0.0836, kịch bản 3 là 0.0059, kịch bản 4 là 0.0062 và kịch bản 5 là 0.0054. Khi quan sát kịch bản 1, 2 và 3 ta thấy rằng, giá trị val_loss cho kết quả cao hơn giá trị train loss và không ổn định, điều này cho thấy mô hình huấn luyện chưa tối ưu và có thể dẫn đến sai lệch trong quá trình dự đoán. Ngược lại, kịch bản 4 và 5 lại cho kết quả tối ưu hơn so với các kịch bản trên khi giá trị val loss bằng với giá trị train loss đối với kịch bản 4 và giá trị val loss thấp hơn so với giá trị train loss đối với kịch bản 5. Tuy nhiên, giá trị val loss trùng với train loss cũng có thể là do vấn đề underfitting, trong khi đó kịch bản 5 lại có giá trị val loss thấp hơn so với giá trị train loss. Điều này cho thấy mô hình trong kịch bản 5 cho kết quả tốt hơn các mô hình trong các kịch bản còn lại.



Hình 4. Độ đo Loss của các kịch bản trong giai đoạn huấn luyện

b. Độ đo Accuracy của các kịch bản


Hình 5 biểu diễn độ chính xác (accuracy) của các kịch bản trong giai đoạn huấn luyện. Kịch bản 1 đạt độ chính xác 96%, kịch bản 2 có độ chính xác là 96.5%. Kịch bản 3, 4 và 5, độ chính xác vượt trội hơn hẳn so với các kịch bản còn lại với độ chính xác là 99%. Mặc khác, khi quan sát kịch bản 1, 2 và 3 ta thấy rằng, giá trị val_accuracy cho kết quả thấp hơn giá trị train accuracy và không ổn định, điều này cho thấy mô hình huấn luyện chưa thật sự hiệu quả và có thể dẫn đến sai lệch trong quá trình dự đoán. Ngược lại, kịch bản 4 và 5 lại cho kết quả tối ưu hơn so với các kịch bản trên khi giá trị val accuracy bằng với giá trị train accuracy đối với kịch bản 4 và giá trị val accuracy cao hơn so với giá trị train accuracy đối với kịch bản 5. Điều này cho thấy hai mô hình trong hai kịch bản 4 và 5 có khả năng dự đoán tốt hơn các mô hình trong ba kịch bản còn lại



Hình 5. Độ đo Accuracy của các kịch bản trong giai đoạn huấn luyện

2. Thời gian huấn luyện

Hình 6 biểu diễn thời gian huấn luyện của các kịch bản đề xuất lần lượt là kịch bản 1 là 39.35 phút, kịch bản 2 là 36.18 phút, kịch bản 3 là 89.65 phút, kịch bản 4 là 42.38 phút và kịch bản 5 là 118.67 phút. Qua kết quả trên, có thể thấy mô hình 2 cho kết quả huấn luyện nhanh hơn so với các kịch bản còn lại.



Hình 6. Thời gian huấn luyện của các kịch bản

D. Kết quả kiểm thử

1. Một số hình ảnh kết quả phân loại

Bảng 2. Một số kết quả trên tập dữ liệu kiểm thử


	Scenario 1	Scenario 2	Scenario 3	Scenario 4	Scenario 5
Malignant					

Benign					
Normal					

Bảng 2 trình bày một số kết quả thực nghiệm của các kịch bản từ 1 đến 5. Ở trường hợp Malignant (ác tính), khối u được hiện rõ trên ảnh nhũ; kịch bản 1 – 4 cho kết quả là Normal, kịch bản 2 cho kết quả là Benign, kịch bản 3 và 5 cho kết quả là Malignant. Ở trường hợp Benign (lành tính), ta thấy rằng các điểm khối u được phân bố nhỏ trên khắp vùng nhũ, kết quả dự đoán ở kịch bản 1 – 2 và 4 cho kết quả dự đoán là Normal, kịch bản 3 là Malignant trong khi kịch bản 5 cho kết quả là Benign (lành tính); đúng với kết quả thực tế. Ở trường hợp Normal, quan sát bảng 2 ta thích kịch bản 1 – 2 – 4 và 5 cho kết quả dự đoán chính xác so với thực tế trong khi kịch bản 3 đưa ra giá trị dự đoán là Benign. Có thể thấy rằng kịch bản 5 cho kết quả chính xác ở cả 3 trường hợp là Malignant, Benign và Normal so với các kịch bản còn lại. Điều này cho thấy, kịch bản 5 hoạt động tốt hơn so với các kịch bản 1, 2, 3 và 4.

2. So sánh, đánh giá kết quả kiểm thử giữa các mô hình

Hình 7a biểu diễn thời gian dự đoán trên tập kiểm thử của các kịch bản đề xuất lần lượt là kịch bản 1 là 1.65 phút, kịch bản 2 là 2.82 phút, kịch bản 3 là 3.56 phút, kịch bản 4 là 5.75 phút và kịch bản 5 là 3.2 phút. Hình 7b biểu diễn độ chính xác dự đoán trên tập kiểm thử của các kịch bản đề xuất lần lượt là kịch bản 1 là 95.2%, kịch bản 2 là 96.3%, kịch bản 3 là 98.1%, kịch bản 4 là 98,6% và kịch bản 5 là 99.2%. Qua kết quả trên, có thể thấy mô hình 5 cho kết quả huấn kiểm thử nhanh hơn so với kịch bản 1 và 4 và chậm hơn so với kịch bản 2 và 3 về mặt thời gian, trái lại, độ chính xác kịch bản 5 mang lại cao hơn so với các kịch bản còn lại. Điều này cho thấy, kịch bản 5 mang lại kết quả dự đoán tốt hơn so với các kịch bản còn lại.



V. KẾT LUẬN

Ung thư vú là căn bệnh phổ biến và gây tử vong cao nhất, khiến việc phát hiện là một nỗ lực đầy thách thức. Tình trạng trở nên tồi tệ hơn mỗi năm và có ít cơ hội hồi phục hơn. Việc phát hiện ung thư ở giai đoạn đầu và tư vấn cho bệnh nhân điều trị luôn là điều cần thiết. Trong bài báo này, chúng tôi đề xuất phương pháp phát hiện và phân loại

ung thư vú dựa trên các mạng rút trích đặc trưng tiêu biểu hiện nay như MobileNetV2, InceptionV3, NASNetLarge, DenseNet121 và mạng Vision Transformer. Đồng thời, chúng tôi cũng cấp tập dữ liệu y sinh của các bệnh nhân ung thư và tạo ra một tập dữ liệu kiểm thử riêng biệt, điều này không những mang lại hiệu suất đánh giá khách quan mà còn chứng minh được hiệu quả của các mô hình khi thực hiện dự đoán. Bên cạnh đó, chúng tôi cũng mang lại một số kết quả so sánh giữa các mô hình, điều này góp phần trong việc đánh giá và lựa chọn được phương pháp phù hợp để có thể xây dựng hệ thống phát hiện và phân loại nhằm hỗ trợ bác sĩ có thể đưa ra chuẩn đoán một cách nhanh chóng để có thể tiến hành điều trị kịp thời cho bệnh nhân. Kết quả thực nghiệm cho thấy mô hình phát hiện ung thư vú dựa trên mạng phân loại Vision Transformer đạt hiệu suất tốt hơn về mặt thời gian dự đoán với độ chính xác cao so với các mạng học sâu khác như NASNetLarge và DenseNet121, các mạng này đã đạt độ chính xác cao trên tập dữ liệu imagenet. Mặt khác, độ chính xác của mô hình đề xuất trong quá trình đào tạo lên đến 99%.

TÀI LIỆU THAM KHẢO

- [1]. R. L. Siegel, K. D. Miller, and A. Jemal, "Cancer statistics". CA Cancer J Clin 2016, vol. 66, pp.7-30.
- [2]. Poorolajal, J., et al, "Breast cancer screening (BCS) chart: a basic and preliminary model for making screening mammography more productive and efficient", J Public Health (Oxf), 2017: p. 1-8.
- [3]. Z. Jiao, X. Gao, Y. Wang, and J. Li, "A deep feature based framework for breast masses classification", Journal of Neurocomputing, vol. 197, pp. 221-231, 2016.
- [4]. C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens and Z. Wojna, "Rethinking the Inception Architecture for Computer Vision", 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 2016, pp. 2818-2826.
- [5]. M. Sandler, A. Howard, M. Zhu, A. Zhmoginov and L. -C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks", 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, UT, USA, 2018, pp. 4510-4520.
- [6] Zoph, Barret & Vasudevan, Vijay & Shlens, Jonathon & Le, Quoc, "Learning Transferable Architectures for Scalable Image Recognition", 8697-8710. 10.1109/CVPR.2018.00907.
- [7] Huang, Gao & Liu, Zhuang & van der Maaten, Laurens & Weinberger, Kilian, "Densely Connected Convolutional Networks" 10.1109/CVPR.2017.243.
- [8]. Simonyan, K.; Zisserman, A., "Very deep convolutional networks for large-scale image recognition.", arXiv 2014, arXiv:1409.1556.
- [9]. Shuyue, G.; Murray, L., "Breast cancer detection using transfer learning in convolutional neural networks", In Proceedings of the 2017 IEEE Applied Imagery Pattern Recognition Workshop (AIPR), Washington, DC, USA, 10–12 October 2017; pp. 1–8.
- [10] Kai Han, Yunhe Wang, Hanting Chen, Xinghao Chen, Jianyuan Guo, Zhenhua Liu, Yehui Tang, An Xiao, Chunjing Xu, Yixing Xu, Zhaohui Yang, Yiman Zhang, and Dacheng Tao Fellow, "A Survey on Vision Transformer", IEEE Transactions on Pattern Analysis and Machine Intelligence, Jan. 2023, pp. 87-110, vol. 45
- [11] Dosovitskiy, A.; Beyer, L.; Kolesnikov, A.; Weissenborn, D.; Zhai, X.; Unterthiner, T.; Dehghani, M.; Minderer, M.; Heigold, G.; Gelly, S.; et al "An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale", arXiv 2020, arXiv:2010.11929.
- [12] Iqbal Z, Luo D, Henry P, Kazemifar S, Rozario T, Yan Y, Westover K, Lu W, Nguyen D, Long T, Wang J, Choy H, Jiang S. , "Accurate real time localization tracking in a clinical environment using Bluetooth Low Energy and deep learning", PLoS One. 2018 Oct 11;13(10):e0205392. PMID: 30307999; PMCID: PMC6181345.
- [13] Gulli, A.; Kapoor, A.; Pal, S., "Deep Learning with TensorFlow 2 and Keras: Regression, ConvNets, GANs, RNNs, NLP, and More with TensorFlow 2 and the Keras API", Packt Publishing Ltd.: Birmingham, UK, 2019.
- [14]. Suckling, J., Parker, J., Dance, D., Astley, S., Hutt, I., Boggis, C., Ricketts, I., et al, "Mammographic Image Analysis Society (MIAS)", database v1.21 [Dataset].
- [15] The American Cancer Society's publications, "Cancer Facts & Figures 2023 and Cancer Facts & Figures 2020", the ACS website; the International Agency for Research on Cancer website; and the National Cancer Institute's Surveillance, Epidemiology, and End Results (SEER) Program.
- [16]. S. Shamy, J. Dheeba, "A research on detection and classification of breast cancer using kmeans GMM & CNN algorithms", International Journal of Engineering and Advanced Technology, vol. 8, no. 6S, pp. 501-505, 2019.
- [17]. V Sansya Vijayan, Lekshmy P L, "Deep learning based prediction of breast cancer in histopathological images," International Journal of Engineering Research & Technology, vol. 8, no. 07, pp.148-152, 2019.
- [18]. Varsha J. Gaikwad, "Detection of breast cancer in mammogram using support vector machine", International Journal of Scientific Engineering and Research, vol. 3, no. 2, pp. 26-30, 2015.

- [19]. M. Aaqib, M. Tufail and S. Anwar, “A Novel Deep Learning Based Approach for Breast Cancer Detection,” 2019 13th International Conference on Mathematics, Actuarial Science, Computer Science and Statistics (MACS), Karachi, Pakistan, 2019, pp. 1-6.
- [20]. Chougrad H, Zouaki H, Alheyane O, “Deep Convolutional Neural Networks for breast cancer screening”, Comput Methods Programs Biomed. 2018 Apr;157:19-30, Epub 2018 Jan 11. PMID: 29477427.
- [21]. Zhong, Ziliang & Zheng, Muhang & Mai, Huafeng & Zhao, Jianan & Liu, Xinyi, (2020), “Cancer image classification based on DenseNet model”, Journal of Physics: Conference Series. 1651. 012143. 10.1088/1742-6596/1651/1/012143.
- [22]. D. Albashish, R. Al-Sayyed, A. Abdullah, M. H. Ryalat and N. Ahmad Almansour, “Deep CNN Model based on VGG16 for Breast Cancer Classification,” 2021 International Conference on Information Technology (ICIT), Amman, Jordan, 2021, pp. 805-810.
- [23]. Girish, Gayathri, Ponnathota Spandana, and Badrish Vasu, “Breast cancer detection using deep learning”, arXiv preprint arXiv:2304.10386 (2023).
- [24]. Mahmud, Md Ishtyaq & Mamun, Muntasir & Abdelgawad, Ahmed, “A Deep Analysis of Transfer Learning Based Breast Cancer Detection Using Histopathology Images”, 10.48550/arXiv.2304.05022, 2023
- [25]. Bitu Asadi, Qurban Memon, “Efficient breast cancer detection via cascade deep learning network”, International Journal of Intelligent Networks, Volume 4, 2023, Pages 46-52
- [26] American Cancer Society, “Breast Cancer Facts & Figures 2019-2020”, Atlanta: American Cancer Society, Inc. 2019.

CLASSIFICATION OF BREAST CANCER ON MAMMOGRAM IMAGES USING DEEP LEARNING MODELS AND VISION TRANSFORMER

Abstract – Breast cancer is the most common diagnosed cancer and the fifth leading cause of death in women. Early detection of this disease not only increases survival rates but also reduces treatment costs. Mammography is currently the imaging method used to detect and diagnose early-stage malignant breast tumors. In this paper, we propose a classification technique based on deep learning network architectures such as NasNetLarge, MobileNetV2, InceptionV3, DenseNet121, and the Vision Transformer classification network to classify breast glandular images as normal, benign, or malignant. Experimental results show that the proposed models achieve an accuracy of up to 99%, providing a supportive solution for screening breast glandular images with abnormalities, allowing doctors to focus on analyzing the results of this classification. As a result, the diagnostic accuracy increases, leading to timely treatment decisions.

Keywords – Vision Transformer, Breast Cancer, Mammography, Deep learning